

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN  
FACULTAD DE CIENCIAS EXACTAS, INGENIERÍA Y AGRIMENSURA  
(FCEIA-UNR)

OPTIMIZACIÓN CONTINUA

Prof. Alejandro G. Marchetti

**Optimización Convexa**



Abril de 2025



## 1. Conjuntos Convexos

### 1.1. Conjuntos Afines y Conjuntos Convexos

#### Líneas y Segmentos

Suponga que  $\mathbf{x}_1$  y  $\mathbf{x}_2$  son dos puntos en  $\mathbb{R}^n$ . Los puntos de la forma

$$\mathbf{x} = \theta\mathbf{x}_1 + (1 - \theta)\mathbf{x}_2,$$

donde  $\theta \in \mathbb{R}$ , forman la *línea* que pasa por  $\mathbf{x}_1$  y  $\mathbf{x}_2$ . El valor del parámetro  $\theta = 0$  corresponde a  $\mathbf{x} = \mathbf{x}_2$  y el valor del parámetro  $\theta = 1$  corresponde a  $\mathbf{x} = \mathbf{x}_1$ . A medida que  $\theta$  se incrementa de 0 a 1, el punto  $\mathbf{x}$  se mueve de  $\mathbf{x}_2$  a  $\mathbf{x}_1$ . Para  $\theta > 1$ , el punto  $\mathbf{x}$  se mueve más allá de  $\mathbf{x}_1$ . Los valores de  $\theta$  entre 0 y 1 corresponden al segmento entre  $\mathbf{x}_1$  y  $\mathbf{x}_2$ . Esto se ilustra en la Figura 1.




Figura 1: Línea que pasa por  $\mathbf{x}_1$  y  $\mathbf{x}_2$ .

#### Conjunto Afín

Un conjunto  $\mathcal{C} \subseteq \mathbb{R}^n$  es *afín* si la línea que pasa por dos puntos cualesquiera de  $\mathcal{C}$  pertenece a  $\mathcal{C}$ , es decir, si para cualquier  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{C}$  y  $\theta \in \mathbb{R}$ , tenemos que  $\theta\mathbf{x}_1 + (1 - \theta)\mathbf{x}_2 \in \mathcal{C}$ . En otras palabras,  $\mathcal{C}$  contiene la combinación lineal de cualquier par de puntos distintos en  $\mathcal{C}$ , provisto que la suma de los coeficientes de la combinación lineal sea igual a uno.

Esta idea se puede generalizar a más de dos puntos. Nos referimos a un punto de la forma  $\theta_1\mathbf{x}_1 + \theta_2\mathbf{x}_2 + \cdots + \theta_k\mathbf{x}_k$ , donde  $\theta_1 + \theta_2 + \cdots + \theta_k = 1$ , como una *combinación afín* de los puntos  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ . Por inducción se puede demostrar que un conjunto afín contiene toda combinación afín de sus puntos: Si  $\mathcal{C}$  es un conjunto afín,  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k \in \mathcal{C}$ , y  $\theta_1 + \theta_2 + \cdots + \theta_k = 1$ , luego el punto  $\theta_1\mathbf{x}_1 + \theta_2\mathbf{x}_2 + \cdots + \theta_k\mathbf{x}_k$  también pertenece a  $\mathcal{C}$ .

Si  $\mathcal{C}$  es un conjunto afín y  $\mathbf{x}_0 \in \mathcal{C}$ , luego el conjunto

$$\mathcal{V} = \mathcal{C} - \mathbf{x}_0 = \{\mathbf{x} - \mathbf{x}_0 | \mathbf{x} \in \mathcal{C}\}$$

es un subespacio. De ello se desprende que el conjunto afín  $\mathcal{C}$  se puede expresar como

$$\mathcal{C} = \mathcal{V} + \mathbf{x}_0 = \{\mathbf{v} + \mathbf{x}_0 | \mathbf{v} \in \mathcal{V}\},$$

es decir, un subespacio más una traslación. El subespacio  $\mathcal{V}$  asociado al conjunto afín  $\mathcal{C}$  no depende de la elección de  $\mathbf{x}_0$ , por lo cual  $\mathbf{x}_0$  se puede elegir como cualquier punto en  $\mathcal{C}$ .

Definimos la *dimensión* de un conjunto afín  $\mathcal{C}$  como la dimensión del subespacio  $\mathcal{V} = \mathcal{C} - \mathbf{x}_0$ , donde  $\mathbf{x}_0$  es cualquier elemento de  $\mathcal{C}$ .

**Ejemplo 1 (Solución de un sistema de ecuaciones lineales)** *La solución de un sistema de ecuaciones lineales,  $\mathcal{C} = \{\mathbf{x} | \mathbf{A}\mathbf{x} = \mathbf{b}\}$ , donde  $\mathbf{A} \in \mathbb{R}^{m \times n}$  y  $\mathbf{b} \in \mathbb{R}^m$ , es un conjunto afín. Para*

para demostrar esto, suponga que  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{C}$ , es decir,  $\mathbf{A}\mathbf{x}_1 = \mathbf{b}$  y  $\mathbf{A}\mathbf{x}_2 = \mathbf{b}$ . Luego, para cualquier  $\theta$  tenemos

$$\begin{aligned} \mathbf{A}(\theta\mathbf{x}_1 + (1 - \theta)\mathbf{x}_2) &= \theta\mathbf{A}\mathbf{x}_1 + (1 - \theta)\mathbf{A}\mathbf{x}_2 \\ &= \theta\mathbf{b} + (1 - \theta)\mathbf{b} \\ &= \mathbf{b}, \end{aligned}$$

lo cual demuestra que la combinación afín  $\theta\mathbf{x}_1 + (1 - \theta)\mathbf{x}_2$  también pertenece a  $\mathcal{C}$ . El subespacio asociado con el conjunto afín  $\mathcal{C}$  es el espacio nulo de  $\mathbf{A}$ .

También se cumple el contrario: todo conjunto afín se puede expresar como el conjunto solución de un sistema de ecuaciones lineales.

### Conjunto Convexo

Un conjunto  $\mathcal{S} \subset \mathbb{R}^n$  es convexo si contiene el segmento entre dos puntos distintos pertenecientes al conjunto, es decir, si para todo  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}$  tenemos

$$\mathbf{x} = \lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2 \in \mathcal{S}, \quad \forall \lambda \in [0, 1]$$

Todo conjunto afín es también convexo, ya que contiene la línea completa entre cualquier par de puntos distintos pertenecientes al conjunto. La Figura 2 ilustra ejemplos de conjuntos convexos y no convexos en  $\mathbb{R}^2$ .




Figura 2: Ejemplos de conjuntos convexos y no convexos. *Izquierda:* El hexágono que incluye su frontera es convexo. *Centro:* El conjunto con forma de riñon no es convexo, ya que existen segmentos entre pares de puntos del conjunto que no están contenidos en el conjunto. *Derecha:* El cuadrado contiene algunos de sus puntos frontera y otros no, y por lo tanto no es convexo.

**Combinación convexa.** Decimos que un punto  $\mathbf{x}$  tal que

$$\mathbf{x} = \theta_1\mathbf{x}_1 + \theta_2\mathbf{x}_2 + \cdots + \theta_k\mathbf{x}_k, \quad \text{con } \sum_{i=1}^k \theta_i = 1, \text{ y } \theta_i \geq 0, \quad i = 1, 2, \dots, k$$

es una *combinación convexa* de los puntos  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ . Se puede demostrar que un conjunto es convexo si y solo si contiene todas las combinaciones convexas de sus puntos.

**Envoltura convexa (o cáscara convexa).** Sea un conjunto  $\mathcal{S} \subset \mathbb{R}^n$ . La envoltura convexa (denominada en inglés *convex hull*) de  $\mathcal{S}$ , denotada  $\text{conv}(\mathcal{S})$ , es el conjunto de todas las combinaciones convexas de puntos es  $\mathcal{S}$ :

$$\text{conv}(\mathcal{S}) = \left\{ \mathbf{x} = \sum_{i=1}^k \theta_i \mathbf{x}_i : \mathbf{x}_i \in \mathcal{S}, \theta_i \geq 0, i = 1, \dots, k, \sum_{i=1}^k \theta_i = 1 \right\}$$

Como el nombre lo indica, la envoltura convexa de un conjunto  $\mathcal{S}$  es siempre un conjunto convexo. Es el menor conjunto convexo que contiene  $\mathcal{S}$ . La Figura 3 ilustra la definición de envoltura convexa.




Figura 3: Envoltura convexa de dos conjuntos en  $\mathbb{R}^2$ . *Izquierda:* La envoltura convexa del conjunto de quince puntos es un pentágono. *Derecha:* La envoltura convexa del conjunto con forma de riñón de la Figura 2 es el conjunto sombreado.

El siguiente lema es consecuencia inmediata de la definición de convexidad. Establece que la intersección de dos conjuntos convexos es convexo y que la suma algebraica de dos conjuntos convexos es también un conjunto convexo.

**Lema 1** Sean  $\mathcal{S}_1$  y  $\mathcal{S}_2$  dos conjuntos convexos en  $\mathbb{R}^n$ . Luego

- 1)  $\mathcal{S}_1 \cap \mathcal{S}_2$  es convexo.
- 2)  $\mathcal{S}_1 \oplus \mathcal{S}_2 = \{\mathbf{x}_1 + \mathbf{x}_2 : \mathbf{x}_1 \in \mathcal{S}_1, \mathbf{x}_2 \in \mathcal{S}_2\}$  es convexo
- 3)  $\mathcal{S}_1 \ominus \mathcal{S}_2 = \{\mathbf{x}_1 - \mathbf{x}_2 : \mathbf{x}_1 \in \mathcal{S}_1, \mathbf{x}_2 \in \mathcal{S}_2\}$  es convexo

**Polítopo.** La envoltura convexa de un número finito de puntos  $\mathbf{x}_1, \dots, \mathbf{x}_{k+1}$  en  $\mathbb{R}^n$  es un polítopo (poliedro acotado). Si  $\mathbf{x}_1, \dots, \mathbf{x}_{k+1}$  son *afínmente independientes*, lo cual significa que  $\mathbf{x}_2 - \mathbf{x}_1, \mathbf{x}_3 - \mathbf{x}_1, \mathbf{x}_{k+1} - \mathbf{x}_1$  son linealmente independientes, luego la envoltura convexa de  $\mathbf{x}_1, \dots, \mathbf{x}_{k+1}$  es un *simplex* de vértices  $\mathbf{x}_1, \dots, \mathbf{x}_{k+1}$ . Un simplex en  $\mathbb{R}^n$  es un polítopo de  $n+1$  vértices.

Por definición, un punto en  $\text{conv}(\mathcal{S})$  puede ser representado como combinación convexa de un número finito de puntos en  $\mathcal{S}$ . El siguiente teorema establece que cualquier punto  $\mathbf{x} \in \text{conv}(\mathcal{S})$  puede ser representado por combinación convexa de a lo sumo  $n+1$  puntos de  $\mathcal{S}$ .

**Teorema 1 (Teorema de Carathéodory)** Sea  $\mathcal{S}$  un conjunto arbitrario en  $\mathbb{R}^n$ . Si  $\mathbf{x} \in \text{conv}(\mathcal{S})$ , luego  $\mathbf{x} \in \text{conv}(\mathbf{x}_1, \dots, \mathbf{x}_{n+1})$  donde  $\mathbf{x}_j \in \mathcal{S}$  para  $j = 1, \dots, n+1$ . En otras palabras,  $\mathbf{x}$  puede ser representado como

$$\begin{aligned}\mathbf{x} &= \sum_{j=1}^{n+1} \lambda_j \mathbf{x}_j \\ \sum_{j=1}^{n+1} \lambda_j &= 1 \\ \lambda_j &\geq 0 \quad \text{para } j = 1, \dots, n+1 \\ \mathbf{x}_j &\in \mathcal{S} \quad \text{para } j = 1, \dots, n+1\end{aligned}$$

**Demostración.** No lo vemos (Teorema 2.1.6 de Bazaraa)

□

## 1.2. Separación y Soporte de Conjuntos

Dado un conjunto  $\mathcal{S}$  convexo y cerrado, y un punto  $\mathbf{y} \notin \mathcal{S}$ , existe un único punto  $\bar{\mathbf{x}} \in \mathcal{S}$  a distancia mínima de  $\mathbf{y}$ , y un hiperplano que separa  $\mathbf{y}$  de  $\mathcal{S}$ .

Para establecer este importante resultado, faremos uso de la siguiente ley del paralelogramo:

**Ley del paralelogramo:** Sean  $\mathbf{a}$  y  $\mathbf{b}$  dos vectores en  $\mathbb{R}^n$ . Luego

$$\begin{aligned}\|\mathbf{a} + \mathbf{b}\|^2 &= \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 + 2\mathbf{a}^\top \mathbf{b} \\ \|\mathbf{a} - \mathbf{b}\|^2 &= \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2\mathbf{a}^\top \mathbf{b}\end{aligned}$$

Sumando obtenemos

$$\|\mathbf{a} + \mathbf{b}\|^2 + \|\mathbf{a} - \mathbf{b}\|^2 = 2\|\mathbf{a}\|^2 + 2\|\mathbf{b}\|^2$$

El resultado se ilustra en la Figura 4 y se puede interpretar como sigue: La suma de las normas al cuadrado de las diagonales de un paralelogramo es igual a la suma de las normas al cuadrado de todos sus lados.




Figura 4: Ley del paralelogramo

**Teorema 2** Sea  $\mathcal{S} \neq \emptyset$ , convexo y cerrado en  $\mathbb{R}^n$ , y  $\mathbf{y} \notin \mathcal{S}$ . Luego, existe un único punto  $\bar{\mathbf{x}} \in \mathcal{S}$  a mínima distancia de  $\mathbf{y}$ . Además,  $\bar{\mathbf{x}}$  minimiza la distancia si y solo si  $(\mathbf{y} - \bar{\mathbf{x}})^\top (\mathbf{x} - \bar{\mathbf{x}}) \leq 0$  para todo  $\mathbf{x} \in \mathcal{S}$ .

**Demostración.** Demostraremos la existencia, unicidad, suficiencia y necesidad.

*Existencia:*  $\mathcal{S} \neq \emptyset$ , luego existe  $\hat{\mathbf{x}} \in \mathcal{S}$ , y podemos buscar el mínimo en

$$\bar{\mathcal{S}} = \mathcal{S} \cap \{\mathbf{x} : \|\mathbf{y} - \mathbf{x}\| \leq \|\mathbf{y} - \hat{\mathbf{x}}\|\}$$

En otras palabras, el problema de hallar el punto más cercano

$$\inf\{\|\mathbf{y} - \mathbf{x}\| : \mathbf{x} \in \mathcal{S}\}$$

es equivalente a

$$\inf\{\|\mathbf{y} - \mathbf{x}\| : \mathbf{x} \in \bar{\mathcal{S}}\}$$

Siendo  $f(\mathbf{x}) = \|\mathbf{y} - \mathbf{x}\|$  una función continua y  $\bar{\mathcal{S}}$  un conjunto compacto no vacío, sabemos que existe un mínimo  $\bar{\mathbf{x}} \in \bar{\mathcal{S}}$  por el Teorema de Weierstrass.

*Unicidad:* Suponga que existe  $\bar{\mathbf{x}}' \in \mathcal{S}$  tal que  $\|\mathbf{y} - \bar{\mathbf{x}}\| = \|\mathbf{y} - \bar{\mathbf{x}}'\| = \gamma$ . Por la convexidad de  $\mathcal{S}$ , tenemos que  $\frac{\bar{\mathbf{x}} + \bar{\mathbf{x}}'}{2} \in \mathcal{S}$ . Por la desigualdad del triángulo, tenemos

$$\left\| \mathbf{y} - \frac{\bar{\mathbf{x}} + \bar{\mathbf{x}}'}{2} \right\| \leq \frac{1}{2} \|\mathbf{y} - \bar{\mathbf{x}}\| + \frac{1}{2} \|\mathbf{y} - \bar{\mathbf{x}}'\| = \gamma.$$

Si la desigualdad fuera estricta, tendríamos una contradicción ya que el punto  $\frac{\bar{x}+\bar{x}'}{2}$  estaría más cercano a  $\mathbf{y}$  que  $\bar{x}$ . Por lo tanto se cumple la igualdad:

$$\left\| \mathbf{y} - \frac{\bar{x} + \bar{x}'}{2} \right\| = \frac{1}{2} \|(\mathbf{y} - \bar{x}) + (\mathbf{y} - \bar{x}')\| = \frac{1}{2} \|\mathbf{y} - \bar{x}\| + \frac{1}{2} \|\mathbf{y} - \bar{x}'\| = \gamma.$$

Por lo tanto, debemos tener  $\mathbf{y} - \bar{x} = \lambda(\mathbf{y} - \bar{x}')$  para algún  $\lambda$ . Como  $\|\mathbf{y} - \bar{x}\| = \|\mathbf{y} - \bar{x}'\| = \gamma$ , debemos tener  $|\lambda| = 1$ . Claramente,  $\lambda \neq -1$ , ya que de lo contrario obtenemos  $\mathbf{y} = (\bar{x} + \bar{x}')/2 \in \mathcal{S}$ , contradiciendo la hipótesis de que  $\mathbf{y} \notin \mathcal{S}$ . Luego,  $\lambda = 1$ , y  $\bar{x}' = \bar{x}$ , estableciéndose la unicidad de la solución óptima.

*Suficiencia:* Sea  $\mathbf{x} \in \mathcal{S}$ . Luego

$$\|\mathbf{y} - \mathbf{x}\|^2 = \|\mathbf{y} - \bar{x} + \bar{x} - \mathbf{x}\|^2 = \|\mathbf{y} - \bar{x}\|^2 + \|\bar{x} - \mathbf{x}\|^2 + 2(\bar{x} - \mathbf{x})^\top(\mathbf{y} - \bar{x})$$

Como  $\|\bar{x} - \mathbf{x}\|^2 \geq 0$ , y  $(\bar{x} - \mathbf{x})^\top(\mathbf{y} - \bar{x}) \geq 0$  por hipótesis, luego  $\|\mathbf{y} - \mathbf{x}\|^2 \geq \|\mathbf{y} - \bar{x}\|^2$ , y por lo tanto  $\bar{x}$  es un minimizador.

*Necesidad:* Suponga que  $\|\mathbf{y} - \mathbf{x}\|^2 \geq \|\mathbf{y} - \bar{x}\|^2$  para todo  $\mathbf{x} \in \mathcal{S}$ . Sea  $\mathbf{x} \in \mathcal{S}$  y note que  $\bar{x} + \lambda(\mathbf{x} - \bar{x}) \in \mathcal{S}$  para  $0 \leq \lambda \leq 1$  por la convexidad de  $\mathcal{S}$ . Luego

$$\|\mathbf{y} - \bar{x} - \lambda(\mathbf{x} - \bar{x})\|^2 \geq \|\mathbf{y} - \bar{x}\|^2 \quad (1)$$

Además,

$$\|\mathbf{y} - \bar{x} - \lambda(\mathbf{x} - \bar{x})\|^2 = \|\mathbf{y} - \bar{x}\|^2 + \lambda^2 \|\mathbf{x} - \bar{x}\|^2 - 2\lambda(\mathbf{y} - \bar{x})^\top(\mathbf{x} - \bar{x}) \quad (2)$$

De (1) y (2) obtenemos

$$2\lambda(\mathbf{y} - \bar{x})^\top(\mathbf{x} - \bar{x}) \leq \lambda^2 \|\mathbf{x} - \bar{x}\|^2 \quad (3)$$

para todo  $\lambda \in [0, 1]$ . Dividiendo (3) por  $\lambda > 0$ , y para  $\lambda \rightarrow 0^+$ , obtenemos  $(\mathbf{y} - \bar{x})^\top(\mathbf{x} - \bar{x}) \leq 0$ .  $\square$

La interpretación del Teorema 5 se ilustra en la Figura 5a. El ángulo entre  $(\mathbf{y} - \bar{x})$  y  $(\mathbf{x} - \bar{x})$  es mayor o igual a  $90^\circ$  para cualquier  $\mathbf{x} \in \mathcal{S}$ , y por lo tanto  $(\mathbf{y} - \bar{x})^\top(\mathbf{x} - \bar{x}) \leq 0$  para todo  $\mathbf{x} \in \mathcal{S}$ . Esto implica que  $\mathcal{S}$  se halla en el hemiespacio  $\mathbf{a}^\top(\mathbf{x} - \bar{x}) \leq 0$  relativo al hiperplano  $\mathbf{a}^\top(\mathbf{x} - \bar{x}) = 0$  que pasa por el punto  $\bar{x}$  y cuyo vector normal es  $\mathbf{a} = (\mathbf{y} - \bar{x})$ . La Figura 5b muestra que esto no se cumple necesariamente si  $\mathcal{S}$  no es convexo.




Figura 5: Distancia mínima a un conjunto convexo cerrado.

### Separación por Hiperplanos

Sean  $\mathcal{S}_1$  y  $\mathcal{S}_2$  conjuntos no vacíos en  $\mathbb{R}^n$ .

- Un hiperplano  $H = \{\mathbf{x} : \mathbf{p}^\top \mathbf{x} = \alpha\}$  separa  $\mathcal{S}_1$  y  $\mathcal{S}_2$  si  $\mathbf{p}^\top \mathbf{x} \geq \alpha$  para todo  $\mathbf{x} \in \mathcal{S}_1$  y  $\mathbf{p}^\top \mathbf{x} \leq \alpha$  para todo  $\mathbf{x} \in \mathcal{S}_2$ .

- Si además  $S_1 \cup S_2 \not\subseteq H$ , entonces  $H$  separa propiamente  $S_1$  y  $S_2$ .
- Si  $\mathbf{p}^\top \mathbf{x} > \alpha$  para todo  $\mathbf{x} \in S_1$  y  $\mathbf{p}^\top \mathbf{x} < \alpha$  para todo  $\mathbf{x} \in S_2$ , entonces  $H$  separa estrictamente  $S_1$  y  $S_2$ .
- Si  $\mathbf{p}^\top \mathbf{x} > \alpha + \varepsilon$  para todo  $\mathbf{x} \in S_1$  y  $\mathbf{p}^\top \mathbf{x} < \alpha$  para todo  $\mathbf{x} \in S_2$ , donde  $\varepsilon > 0$ , entonces  $H$  separa fuertemente  $S_1$  y  $S_2$ .

La Figura 6 muestra los distintos tipos de separación. Por supuesto, separación fuerte implica separación estricta, que a su vez implica separación propia, que a su vez implica separación.




Figura 6: Varios tipos de separación.

### Separación de un Conjunto Convexo y un Punto

**Teorema 3 (Teorema de Separación)** Sea  $S \neq \emptyset$  cerrado y convexo en  $\mathbb{R}^n$  e  $\mathbf{y} \notin S$ . Luego, existe un vector  $\mathbf{p} \neq \mathbf{0}$  y un escalar  $\alpha$  tal que  $\mathbf{p}^\top \mathbf{y} > \alpha$  y  $\mathbf{p}^\top \mathbf{x} \leq \alpha$  para todo  $\mathbf{x} \in S$ .

**Demostración.** El conjunto  $S \neq \emptyset$  es cerrado y convexo en  $\mathbb{R}^n$  e  $\mathbf{y} \notin S$ . Luego, existe un único mínimo  $\bar{\mathbf{x}} \in S$  tal que  $(\mathbf{x} - \bar{\mathbf{x}})^\top (\mathbf{y} - \bar{\mathbf{x}}) \leq 0$  para todo  $\mathbf{x} \in S$ . Tomando  $\mathbf{p} = \mathbf{y} - \bar{\mathbf{x}} \neq \mathbf{0}$  y  $\alpha = \bar{\mathbf{x}}^\top (\mathbf{y} - \bar{\mathbf{x}}) = \mathbf{p}^\top \bar{\mathbf{x}}$ , tenemos que  $\mathbf{p}^\top \mathbf{x} \leq \alpha$  para todo  $\mathbf{x} \in S$ . Además,  $\mathbf{p}^\top \mathbf{y} - \alpha = (\mathbf{y} - \bar{\mathbf{x}})^\top (\mathbf{y} - \bar{\mathbf{x}}) = \|\mathbf{y} - \bar{\mathbf{x}}\|^2 > 0$ .  $\square$

### Teorema de Farkas

**Teorema 4 (Teorema de Farkas)** Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$  y  $\mathbf{c} \in \mathbb{R}^n$ . Luego, exactamente uno de los sistemas siguientes tiene solución:

- S1:  $\mathbf{A}\mathbf{x} \leq \mathbf{0}$  y  $\mathbf{c}^\top \mathbf{x} > 0$  para algún  $\mathbf{x} \in \mathbb{R}^n$ .  
S2:  $\mathbf{A}^\top \mathbf{y} = \mathbf{c}$  e  $\mathbf{y} \geq \mathbf{0}$  para algún  $\mathbf{y} \in \mathbb{R}^m$ .

**Demostración.** Ver demostración en Teorema 2.4.5 de Bazaraa.  $\square$

**Interpretación del Teorema de Farkas:** Sean  $\mathbf{a}_1, \dots, \mathbf{a}_m$  las columnas de  $\mathbf{A}^\top$ . Luego

- S2 tiene solución si  $\mathbf{c}$  pertenece al cono convexo generado por  $\mathbf{a}_1, \dots, \mathbf{a}_m$ .
- S1 tiene solución si el cono convexo cerrado  $\{\mathbf{x} : \mathbf{Ax} \leq \mathbf{0}\}$  intersecta con el hemiespacio abierto  $\{\mathbf{x} : \mathbf{c}^T \mathbf{x} > 0\}$ .

Estos dos casos se ilustran geométricamente en la Figura 7.




Figura 7: Teorema de Farkas.

**Corolario 1 (Teorema de Gordan)** Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$ . Exactamente uno de los sistemas siguientes tiene solución:

- S1:  $\mathbf{Ax} < \mathbf{0}$  para algún  $\mathbf{x} \in \mathbb{R}^n$ .  
S2:  $\mathbf{A}^T \mathbf{y} = \mathbf{0}$  e  $\mathbf{y} \geq \mathbf{0}$  para algún  $\mathbf{y} \neq \mathbf{0}$ ,  $\mathbf{y} \in \mathbb{R}^m$ .

**Demostración.** Ver demostración en Corolario 1 de Bazaraa. □

### Soporte de Conjuntos en Puntos Frontera

**Definición.** Sea  $\mathcal{S} \neq \emptyset$  un conjunto en  $\mathbb{R}^n$ , y sea  $\bar{\mathbf{x}} \in \partial\mathcal{S}$ .  $H = \{\mathbf{x} : \mathbf{p}^T(\mathbf{x} - \bar{\mathbf{x}}) = 0\}$  es un hiperplano soporte de  $\mathcal{S}$  en  $\bar{\mathbf{x}}$  si:

$$\mathcal{S} \subseteq H^+, \text{ es decir, } \mathbf{p}^T(\mathbf{x} - \bar{\mathbf{x}}) \geq 0, \quad \forall \mathbf{x} \in \mathcal{S}.$$

o bien

$$\mathcal{S} \subseteq H^-, \text{ es decir, } \mathbf{p}^T(\mathbf{x} - \bar{\mathbf{x}}) \leq 0, \quad \forall \mathbf{x} \in \mathcal{S}.$$

donde  $H^+$  es el hemiespacio positivo y  $H^-$  es el hemiespacio negativo. Si además  $\mathcal{S} \not\subseteq H$ , luego  $H$  es un hiperplano soporte propio de  $\mathcal{S}$  en  $\bar{\mathbf{x}}$ .

La Figura 8 muestra algunos ejemplos de hiperplanos soporte. Se muestra el caso de un hiperplano soporte único en un punto frontera, un número infinito de hiperplanos soporte en un punto frontera, y un hiperplano soporte en más de un punto.

El siguiente teorema establece que un conjunto convexo tiene un hiperplano soporte en cada punto de su frontera.

**Teorema 5** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $\bar{\mathbf{x}} \in \partial\mathcal{S}$ . Luego, existe un hiperplano que soporta  $\mathcal{S}$  en  $\bar{\mathbf{x}}$ , es decir, existe  $\mathbf{p} \neq \mathbf{0}$  tal que  $\mathbf{p}^T(\mathbf{x} - \bar{\mathbf{x}}) \leq 0$  para todo  $\mathbf{x} \in \text{cl}(\mathcal{S})$ .




Figura 8: Hiperplanos soporte.

**Demostración.** Ver demostración en Teorema 2.4.7 de Bazaraa.  $\square$

**Corolario 2** Sea  $S \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$  y  $\bar{x} \notin \text{int } S$ . Luego existe un vector  $p \neq 0$  tal que  $p^T(x - \bar{x}) \leq 0$  para todo  $x \in \text{cl } S$ .

**Demostración.** Si  $\bar{x} \in \text{cl } S$ , el corolario es cierto por el Teorema 3. Por otro lado, si  $\bar{x} \in \partial S$ , el corolario se reduce al Teorema 5.  $\square$

### Separación de Dos Conjuntos Convexos Disjuntos

Dos conjuntos convexos disjuntos pueden ser separados por un hiperplano  $H$  tal que uno de los conjuntos pertenezca a  $H^+$  y el otro pertenezca a  $H^-$ . De hecho, este resultado es válido aún si los conjuntos comparten algunos puntos, siempre y cuando sus interiores sean disjuntos.

**Teorema 6** Sean  $S_1$  y  $S_2$  conjuntos convexos disjuntos no vacíos en  $\mathbb{R}^n$ , tales que  $S_1 \cap S_2 = \emptyset$ . Luego, existe un hiperplano que separa  $S_1$  y  $S_2$ , es decir, existe  $p \in \mathbb{R}^n$ ,  $p \neq 0$ , tal que

$$\inf\{p^T x : x \in S_1\} \geq \sup\{p^T x : x \in S_2\}$$

**Demostración.** Sea  $S = S_1 \ominus S_2 = \{x_1 - x_2 : x_1 \in S_1; x_2 \in S_2\}$ . Notar que  $S$  es un conjunto convexo. Además,  $0 \notin S$  porque de lo contrario  $S_1 \cap S_2 \neq \emptyset$ . Por el Corolario 2 del Teorema 5, existe  $p \neq 0$  tal que  $p^T x \geq 0$  para todo  $x \in S$ . Esto significa que  $p^T x_1 \geq p^T x_2$  para todo  $x_1 \in S_1$  y  $x_2 \in S_2$ .  $\square$

**Definición 1 (Conos)**  $C \neq \emptyset$  en  $\mathbb{R}^n$  es un cono con vértice en cero si  $\bar{x} \in C$  implica que  $\lambda \bar{x} \in C$  para todo  $\lambda \geq 0$ . Si además  $C$  es convexo, entonces  $C$  es un cono convexo. Ver Figura 9.

**Definición 2 (Punto Extremo)** Sea  $S \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ . Un vector  $x \in S$  es un punto extremo de  $S$  si  $x = \alpha x_1 + (1 - \alpha)x_2$  con  $x_1, x_2 \in S$  y  $\alpha \in (0, 1)$  implica que  $x = x_1 = x_2$ .

## 2. Funciones Convexas

### 2.1. Definición de Funciones Convexas y Propiedades

**Definición.** Sea  $f : S \rightarrow \mathbb{R}$ ,  $S \neq \emptyset$  convexo en  $\mathbb{R}^n$ . La función  $f$  es *convexa* en  $S$  si

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2), \quad \forall x_1, x_2 \in S, \quad \forall \lambda \in (0, 1) \quad (4)$$




Figura 9: Conos.

Se dice que  $f$  es *estrictamente convexa* en  $\mathcal{S}$  si

$$f(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) < \lambda f(\mathbf{x}_1) + (1 - \lambda) f(\mathbf{x}_2), \quad \forall \mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}, \mathbf{x}_1 \neq \mathbf{x}_2, \text{ y } \forall \lambda \in (0, 1)$$

Se dice que  $f$  es (estRICTAMENTE) *cóncava* en  $\mathcal{S}$  si  $-f$  es (estRICTAMENTE) convexa en  $\mathcal{S}$ .

La Figura 10 ilustra ejemplos de una función convexa, una función cóncava, y una función que no es ni convexa ni cóncava.




Figura 10: Función convexa, función cóncava, y función que no es convexa ni cóncava.

Algunas funciones convexas importantes:

- 1) Sean  $f_1, f_2, \dots, f_k : \mathbb{R}^n \rightarrow \mathbb{R}$  funciones convexas. Luego:
  - a)  $f(\mathbf{x}) = \sum_{j=1}^k \alpha_j f_j(\mathbf{x})$ , con  $\alpha_j > 0$  para  $j = 1, \dots, k$ , es una función convexa.
  - b)  $f(\mathbf{x}) = \max \{f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_k(\mathbf{x})\}$  es una función convexa.
- 2) Sea  $g : \mathbb{R}^n \rightarrow \mathbb{R}$  una función convexa. Sea  $\mathcal{S} = \{\mathbf{x} : g(\mathbf{x}) > 0\}$ . Defina  $f : \mathcal{S} \rightarrow \mathbb{R}$  como  $f(\mathbf{x}) = \frac{1}{g(\mathbf{x})}$ . Luego  $f$  es convexa en  $\mathcal{S}$ .
- 3) Sea  $g : \mathbb{R} \rightarrow \mathbb{R}$  una función no decreciente, univariada y convexa, y sea  $h : \mathbb{R}^n \rightarrow \mathbb{R}$  una función convexa. Luego, la función compuesta  $f(\mathbf{x}) = g(h(\mathbf{x}))$  es convexa.

**Conjunto de nivel de  $f(\mathbf{x})$ :** Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  convexa. Luego  $\mathcal{S}_\alpha = \{\mathbf{x} \in \mathcal{S} : f(\mathbf{x}) \leq \alpha\}$  es un conjunto convexo.

**Lema 2** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa. Luego, el conjunto de nivel  $\mathcal{S}_\alpha = \{\mathbf{x} \in \mathcal{S} : f(\mathbf{x}) \leq \alpha\}$ , donde  $\alpha \in \mathbb{R}$ , es un conjunto convexo.

**Demostración.** Sean  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}_\alpha$ . Luego  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}$  y  $f(\mathbf{x}_1) \leq \alpha, f(\mathbf{x}_2) \leq \alpha$ . Sea  $\lambda \in (0, 1)$  y  $\mathbf{x} = \lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2$ . Por convexidad de  $\mathcal{S}$ ,  $\mathbf{x} \in \mathcal{S}$ . Por convexidad de  $f$ ,

$$f(\mathbf{x}) \leq \lambda f(\mathbf{x}_1) + (1 - \lambda)f(\mathbf{x}_2) \leq \lambda\alpha + (1 - \lambda)\alpha = \alpha$$

Luego,  $\mathbf{x} \in \mathcal{S}_\alpha$  y  $\mathcal{S}_\alpha$  es convexo.  $\square$

### Continuidad de Funciones Convexas

Las funciones cóncavas y convexas son continuas en el interior de su dominio.

**Teorema 7** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa. Luego,  $f$  es continua en  $\text{int}(\mathcal{S})$ .*

**Demostración.** La demostración se encuentra en el Teorema 3.1.3 de Bazaraa.  $\square$

### Derivada Direccional de Funciones Convexas

**Definición 3** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$ . Sea  $\bar{\mathbf{x}} \in \mathcal{S}$  y el vector  $\mathbf{d} \neq \mathbf{0}$  tal que  $\bar{\mathbf{x}} + \lambda\mathbf{d} \in \mathcal{S}$  para  $\lambda > 0$  suficientemente pequeño. Luego, la derivada direccional de  $f$  en la dirección de  $\mathbf{d}$ , en caso de existir, está dada por:*

$$f'(\bar{\mathbf{x}}, \mathbf{d}) = \nabla_{\mathbf{d}} f(\bar{\mathbf{x}}) = \lim_{\lambda \rightarrow 0^+} \frac{f(\bar{\mathbf{x}} + \lambda\mathbf{d}) - f(\bar{\mathbf{x}})}{\lambda}$$

En particular, el límite de la Definición 3 existe para funciones cóncavas y convexas definidas globalmente. Si  $f : \mathcal{S} \rightarrow \mathbb{R}$  es convexa en  $\mathcal{S}$ , el límite existe si  $\bar{\mathbf{x}} \in \text{int}(\mathcal{S})$ , pero puede no existir si  $\bar{\mathbf{x}} \in \partial\mathcal{S}$ .

## 2.2. Epígrafo e Hipógrafo de una Función

Una función  $f$  en  $\mathcal{S}$  puede describirse por medio del conjunto:

$$\{[\mathbf{x}, f(\mathbf{x})] : \mathbf{x} \in \mathcal{S}\} \subset \mathbb{R}^{n+1}$$

que se conoce como *grafo* de una función.

**Definición 4 (Epígrafo)** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$ . El epígrafo de  $f$ , denotado  $\text{epif}$  es un subconjunto de  $\mathbb{R}^{n+1}$  definido como*

$$\{(\mathbf{x}, y) : \mathbf{x} \in \mathcal{S}, y \in \mathbb{R}, y \geq f(\mathbf{x})\}$$

*El hipógrafo de  $f$ , denotado  $\text{hypf}$  es un subconjunto de  $\mathbb{R}^{n+1}$  dado por*

$$\{(\mathbf{x}, y) : \mathbf{x} \in \mathcal{S}, y \in \mathbb{R}, y \leq f(\mathbf{x})\}$$

La Figura 11 ilustra el epígrafo y el hipógrafo de varias funciones. En la Figura 11a, ni el epígrafo ni el hipógrafo de  $f$  son conjuntos convexos. En la Figura 11b, el epígrafo de  $f$  es un conjunto convexo, mientras que en la Figura 11c, el hipógrafo de  $f$  es convexo.

Una función resulta ser convexa si y solo si su epígrafo es un conjunto convexo, y en forma equivalente, una función es cóncava si y solo si su hipógrafo es un conjunto convexo.

**Teorema 8** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$ . Luego,  $f$  es convexa si y solo si  $\text{epif}$  es un conjunto convexo.*




Figura 11: Epígrafos e Hipógrafos.

**Demostración.** Suponga que  $f$  es convexa, y sea  $(\mathbf{x}_1, y_1)$  y  $(\mathbf{x}_2, y_2) \in \text{epif}$ , es decir,  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}$ ,  $y_1 \geq f(\mathbf{x}_1)$  e  $y_2 \geq f(\mathbf{x}_2)$ . Sea  $\lambda \in (0, 1)$ . Luego

$$\lambda y_1 + (1 - \lambda)y_2 \geq \lambda f(\mathbf{x}_1) + (1 - \lambda)f(\mathbf{x}_2) \geq f(\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2),$$

donde la última desigualdad vale por la convexidad de  $f$ . Notar que  $\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2 \in \mathcal{S}$ . Luego,  $[\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2, \lambda y_1 + (1 - \lambda)y_2] \in \text{epif}$ , y por lo tanto  $\text{epif}$  es convexo.

A la inversa, suponga que  $\text{epif}$  es convexo, y sean  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}$ . Luego  $[\mathbf{x}_1, f(\mathbf{x}_1)]$  y  $[\mathbf{x}_2, f(\mathbf{x}_2)]$  pertenecen a  $\text{epif}$ , y por la convexidad de  $\text{epif}$ , debemos tener

$$[\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2, \lambda f(\mathbf{x}_1) + (1 - \lambda)f(\mathbf{x}_2)] \in \text{epif}, \quad \text{para } \lambda \in (0, 1).$$

En otras palabras,  $\lambda f(\mathbf{x}_1) + (1 - \lambda)f(\mathbf{x}_2) \geq f[\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2]$  para todo  $\lambda \in (0, 1)$ , es decir,  $f$  es convexa. Esto completa la demostración.  $\square$

Dado que el epígrafo de una función convexa, y el hipógrafo de una función cóncava son conjuntos convexos, tienen hiperplanos soporte en sus puntos frontera.

### 2.3. Subgradientes

**Definición 5** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa. Luego  $\xi$  es un subgradiente de  $f$  en  $\bar{\mathbf{x}} \in \mathcal{S}$  si

$$f(\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \xi^T(\mathbf{x} - \bar{\mathbf{x}}), \quad \forall \mathbf{x} \in \mathcal{S}$$

Similarmente, sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función cóncava. Luego  $\xi$  es un subgradiente de  $f$  en  $\bar{\mathbf{x}} \in \mathcal{S}$  si

$$f(\mathbf{x}) \leq f(\bar{\mathbf{x}}) + \xi^T(\mathbf{x} - \bar{\mathbf{x}}), \quad \forall \mathbf{x} \in \mathcal{S}$$

La Figura 12 muestra ejemplos de subgradientes de funciones convexas y cóncavas.

En la figura vemos que  $f(\bar{\mathbf{x}}) + \xi^T(\mathbf{x} - \bar{\mathbf{x}})$  corresponde a un hiperplano soporte del epígrafo (o hipógrafo) de  $f$ . El subgradiente  $\xi$  es la pendiente del hiperplano soporte.

Más precisamente, el hiperplano soporte del epígrafo (o hipógrafo) de  $f$  está dado por:

$$\mathbf{p}^T \left[ \begin{pmatrix} \mathbf{x} \\ y \end{pmatrix} - \begin{pmatrix} \bar{\mathbf{x}} \\ f(\bar{\mathbf{x}}) \end{pmatrix} \right] = 0, \quad \text{con } \mathbf{p} = \begin{pmatrix} \xi \\ -1 \end{pmatrix}$$




Figura 12: Interpretación geométrica de subgradientes.

Reemplazando tenemos

$$(\xi^\top - 1) \begin{pmatrix} \mathbf{x} \\ y \end{pmatrix} - (\xi^\top - 1) \begin{pmatrix} \bar{\mathbf{x}} \\ f(\bar{\mathbf{x}}) \end{pmatrix} = 0,$$

de donde obtenemos

$$y = f(\bar{\mathbf{x}}) + \xi^\top (\mathbf{x} - \bar{\mathbf{x}})$$

**Ejemplo 2** Sea  $f(x) = \min\{f_1(x), f_2(x)\}$ , donde  $f_1$  y  $f_2$  se definen como:

$$\begin{aligned} f_1(x) &= 4 - |x|, & x \in \mathbb{R} \\ f_2(x) &= 4 - (x - 2)^2, & x \in \mathbb{R} \end{aligned}$$

Debido a que  $f_2(x) \geq f_1(x)$  para  $1 \leq x \leq 4$ ,  $f$  se puede representar como:

$$f(x) = \begin{cases} 4 - x, & x \in [1, 4] \\ 4 - (x - 2)^2, & x \notin [1, 4] \end{cases}$$

La función cóncava  $f$  se muestra en la Figura 13 en líneas negras gruesas. Tenemos que

$$\xi = \begin{cases} -1, & x \in (1, 4) \\ -2(x - 2), & x < 1, x > 4 \end{cases}$$

En  $x = 1$  y en  $x = 4$  los subgradientes no son únicos ya que existen muchos hiperplanos soporte.

$$\begin{cases} \xi \in [-1, 2], & x = 1 \\ \xi \in [-4, -1], & x = 4 \end{cases}$$

El siguiente teorema muestra que toda función convexa o cóncava tiene al menos un subgradiente en el interior de su dominio.

**Teorema 9** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa. Luego para  $\bar{\mathbf{x}} \in \text{int}\mathcal{S}$ , existe un vector  $\xi$  tal que el hiperplano

$$H = \{(\mathbf{x}, y) : y = f(\bar{\mathbf{x}}) + \xi^\top (\mathbf{x} - \bar{\mathbf{x}})\}$$

soporta  $\text{epif } f$  en  $[\bar{\mathbf{x}}, f(\bar{\mathbf{x}})]$ . En particular,

$$f(\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \xi^\top (\mathbf{x} - \bar{\mathbf{x}}), \quad \text{para todo } \mathbf{x} \in \mathcal{S},$$

es decir,  $\xi$  es un subgradiente de  $f$  en  $\bar{\mathbf{x}}$ .

**Demostración.** Ver demostración del Teorema 3.2.5 de Bazaraa. □




Figura 13: Función del Ejemplo 2.

## 2.4. Funciones Convexas Diferenciables

**Lema 3** Si  $f$  es diferenciable en  $\bar{\mathbf{x}}$ , luego la derivada direccional existe a lo largo de cualquier vector  $\mathbf{v}$ , y se tiene

$$\nabla_{\mathbf{v}} f(\bar{\mathbf{x}}) = \lim_{\lambda \rightarrow 0^+} \frac{f(\bar{\mathbf{x}} + \lambda \mathbf{v}) - f(\bar{\mathbf{x}})}{\lambda} = \nabla f(\bar{\mathbf{x}}) \mathbf{v}$$

donde  $\nabla f(\bar{\mathbf{x}}) \in \mathbb{R}^{1 \times n}$  es el gradiente de  $f$  en  $\bar{\mathbf{x}}$ .

Una función convexa diferenciable tiene un único subgradiente  $\xi^T = \nabla f(\mathbf{x})$ .

**Lema 4** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa. Si  $f$  es diferenciable en  $\bar{\mathbf{x}} \in \text{int}\mathcal{S}$ , luego  $\nabla f(\mathbf{x})$  es el único subgradiente de  $f$  en  $\bar{\mathbf{x}}$ .

**Demostración.** Ver demostración en Lema 3.3.2 de Bazaraa. □

**Teorema 10 (Condición de primer orden)** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo, y sea  $f \in C^1$ ,  $f : \mathcal{S} \rightarrow \mathbb{R}$ . Luego,  $f$  es convexa en  $\mathcal{S}$  si y solo si para todo  $\bar{\mathbf{x}} \in \mathcal{S}$  se cumple:

$$f(\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}}), \quad \forall \mathbf{x} \in \mathcal{S}$$

**Demostración.** Primero suponga que  $f$  es convexa. Luego para todo  $\lambda \in [0, 1]$  tenemos

$$f(\lambda \mathbf{x} + (1 - \lambda) \bar{\mathbf{x}}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\bar{\mathbf{x}})$$

Luego, para  $0 < \lambda \leq 1$  tenemos

$$\frac{f(\bar{\mathbf{x}} + \lambda(\mathbf{x} - \bar{\mathbf{x}})) - f(\bar{\mathbf{x}})}{\lambda} \leq f(\mathbf{x}) - f(\bar{\mathbf{x}})$$

Tomando el límite cuando  $\lambda \rightarrow 0^+$  obtenemos

$$\nabla f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}}) \leq f(\mathbf{x}) - f(\bar{\mathbf{x}})$$

A la inversa, suponga que

$$f(\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}}), \quad \forall \bar{\mathbf{x}}, \mathbf{x} \in \mathcal{S} \tag{5}$$

Seleccionando  $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{S}$  y  $\lambda \in [0, 1]$  con  $\bar{\mathbf{x}} = \lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2$  y alternativamente  $\mathbf{x} = \mathbf{x}_1$  o  $\mathbf{x} = \mathbf{x}_2$ , tenemos:

$$f(\mathbf{x}_1) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x}_1 - \bar{\mathbf{x}}) \quad (6)$$

$$f(\mathbf{x}_2) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x}_2 - \bar{\mathbf{x}}) \quad (7)$$

Multiplicando (6) por  $\lambda$  y (7) por  $(1 - \lambda)$  y sumando:

$$\lambda f(\mathbf{x}_1) + (1 - \lambda)(\mathbf{x}_2) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2 - \bar{\mathbf{x}})$$

Sustituyendo  $\bar{\mathbf{x}} = \lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2$  obtenemos

$$\lambda f(\mathbf{x}_1) + (1 - \lambda)(\mathbf{x}_2) \geq f(\lambda\mathbf{x}_1 + (1 - \lambda)\mathbf{x}_2)$$

lo cual concluye la demostración.  $\square$

El enunciado del Teorema 10 se ilustra en la Figura 14. La función afín  $f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}})$  es una cota inferior de  $f(\mathbf{x})$  para cualquier  $\bar{\mathbf{x}} \in \mathcal{S}$ .




Figura 14: Ilustración del Teorema 10.

**Teorema 11 (Condición de segundo orden)** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto abierto y convexo en  $\mathbb{R}^n$ , y sea  $f \in C^2$ ,  $f : \mathcal{S} \rightarrow \mathbb{R}$ . Luego,  $f$  es convexa en  $\mathcal{S}$  si y solo si la matriz hessiana de  $f$  es positiva semidefinida (PSD) para todo  $\mathbf{x} \in \mathcal{S}$ .*

**Demostración.** Suponga que  $f$  es convexa, y sea  $\bar{\mathbf{x}} \in \mathcal{S}$ . Debemos mostrar que  $\mathbf{x}^\top [\nabla^2 f(\bar{\mathbf{x}})]\mathbf{x} \geq 0$ ,  $\forall \mathbf{x} \in \mathbb{R}^n$ .  $\mathcal{S}$  es abierto, luego para cualquier  $\mathbf{x} \in \mathbb{R}^n$ ,  $\bar{\mathbf{x}} + \lambda\mathbf{x} \in \mathcal{S}$  para  $|\lambda| \neq 0$  y suficientemente pequeño. Luego, por el Teorema 10 y dado que  $f \in C^2$ , obtenemos las siguientes dos expresiones:

$$f(\bar{\mathbf{x}} + \lambda\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \lambda \nabla f(\bar{\mathbf{x}})\mathbf{x} \quad (8)$$

$$f(\bar{\mathbf{x}} + \lambda\mathbf{x}) = f(\bar{\mathbf{x}}) + \lambda \nabla f(\bar{\mathbf{x}})\mathbf{x} + \frac{1}{2}\lambda^2 \mathbf{x}^\top [\nabla^2 f(\bar{\mathbf{x}})]\mathbf{x} + o(\lambda^2 \|\mathbf{x}\|^2) \quad (9)$$

Restando (9) de (8):

$$\frac{1}{2}\lambda^2 \mathbf{x}^\top [\nabla^2 f(\bar{\mathbf{x}})]\mathbf{x} + o(\lambda^2 \|\mathbf{x}\|^2) \geq 0$$

Dividiendo por  $\lambda^2$  y para  $\lambda \rightarrow 0$ , obtenemos:

$$\frac{1}{2}\lambda^2\mathbf{x}^\top[\nabla^2 f(\bar{\mathbf{x}})]\mathbf{x} \geq 0$$

A la inversa, supongamos ahora que  $\nabla^2 f(\bar{\mathbf{x}})$  es positiva semidefinida para todo  $\mathbf{x} \in \mathcal{S}$ . Consideré  $\mathbf{x}, \bar{\mathbf{x}} \in \mathcal{S}$ . Por el teorema del valor medio:

$$f(\mathbf{x}) = f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}}) + \frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}})^\top[\nabla^2 f(\hat{\mathbf{x}})](\mathbf{x} - \bar{\mathbf{x}}),$$

donde  $\hat{\mathbf{x}} = \lambda\bar{\mathbf{x}} + (1 - \lambda)\mathbf{x}$  para algún  $\lambda \in (0, 1)$ . Notar que  $\hat{\mathbf{x}} \in \mathcal{S}$ . Luego, por hipótesis,  $(\mathbf{x} - \bar{\mathbf{x}})^\top[\nabla^2 f(\hat{\mathbf{x}})](\mathbf{x} - \bar{\mathbf{x}}) \geq 0$ , de donde concluimos que

$$f(\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}}), \quad \forall \mathbf{x}, \bar{\mathbf{x}} \in \mathcal{S}.$$

Luego, se cumple la condición de primer orden del Teorema 10 y  $f$  es convexa.  $\square$

El Teorema 11 es útil para verificar la convexidad o concavidad de una función dos veces diferenciable. En particular, si la función es cuadrática, luego la matriz hessiana es independiente del punto  $\mathbf{x}$ . En este caso, verificar la convexidad se reduce a verificar que una matriz constante sea positiva semidefinida.

**Teorema 12** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f \in C^2$ ,  $f : \mathcal{S} \rightarrow \mathbb{R}$ . Si  $\nabla^2 f(\mathbf{x})$  es definida positiva  $\forall \mathbf{x} \in \mathcal{S}$ , luego  $f$  es estrictamente convexa. Por el contrario, si  $f$  es estrictamente convexa, luego  $\nabla^2 f(\mathbf{x})$  es definida semipositiva  $\forall \mathbf{x} \in \mathcal{S}$ . Sin embargo, si  $f$  es estrictamente convexa y cuadrática, luego  $\nabla^2 f(\mathbf{x})$  es definida positiva  $\forall \mathbf{x} \in \mathcal{S}$ .*

**Demostración.** Ver Teorema 3.3.8 de Bazaraa.  $\square$

**Ejemplo 3** Considere la función  $f(x) = x^4$ . Tenemos que  $\nabla^2 f(x) = 12x^2$  es definida positiva para todo  $x \neq 0$  pero es positiva semidefinida para  $x = 0$ . Notar que  $f(x) = x^4$  es estrictamente convexa a pesar de que  $\nabla^2 f(0) = 0$ .

### 3. Minimización y Maximización de Funciones Convexas

Los problemas de optimización

$$\min_{\mathbf{x} \in \mathcal{S}} f(\mathbf{x})$$

donde  $f$  es una función convexa y  $\mathcal{S}$  es un conjunto convexo, se conocen como *problemas de optimización convexos*.

El principal resultado para problemas de optimización convexos es que cada mínimo local es también un mínimo global.

**Teorema 13** *Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa en  $\mathcal{S}$ . Considerar el problema  $\min_{\mathbf{x} \in \mathcal{S}} f(\mathbf{x})$ . Sea  $\mathbf{x}^* \in \mathcal{S}$  una solución óptima local.*

- 1) Luego,  $\mathbf{x}^*$  es una solución óptima global.
- 2) Si  $\mathbf{x}^*$  es un mínimo local estricto, o si  $f$  es estrictamente convexa, luego  $\mathbf{x}^*$  es la única solución óptima global.

**Demostración.** Demostraremos el ítem (1). Dado que  $\mathbf{x}^*$  es un mínimo local, luego existe un entorno- $\varepsilon$ ,  $B_\varepsilon(\mathbf{x}^*)$ , tal que

$$f(\mathbf{x}) \geq f(\mathbf{x}^*), \quad \forall \mathbf{x} \in \mathcal{S} \cap B_\varepsilon(\mathbf{x}^*)$$

Por contradicción, suponga que  $\mathbf{x}^*$  no es un óptimo global. Luego, existe  $f(\hat{\mathbf{x}}) < f(\mathbf{x}^*)$  para algún  $\hat{\mathbf{x}} \in \mathcal{S}$ . Por la convexidad de  $f$  la siguiente desigualdad se cumple para todo  $\lambda \in [0, 1]$ :

$$f(\lambda\hat{\mathbf{x}} + (1 - \lambda)\mathbf{x}^*) \leq \lambda f(\hat{\mathbf{x}}) + (1 - \lambda)f(\mathbf{x}^*) < \lambda f(\mathbf{x}^*) + (1 - \lambda)f(\mathbf{x}^*) = f(\mathbf{x}^*)$$

Pero para  $\lambda > 0$  suficientemente pequeño,  $\lambda\hat{\mathbf{x}} + (1 - \lambda)\mathbf{x}^* \in \mathcal{S} \cap B_\varepsilon(\mathbf{x}^*)$ , por lo que la desigualdad anterior resulta en una contradicción.  $\square$

**Teorema 14** Sea  $\mathcal{S} \neq \emptyset$  un conjunto convexo en  $\mathbb{R}^n$ , y sea  $f \in C^1$ ,  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa en  $\mathcal{S}$ . Sea  $\mathbf{x}^* \in \mathcal{S}$  tal que para todo  $\mathbf{x} \in \mathcal{S}$ :

$$\nabla f(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) \geq 0,$$

luego  $\mathbf{x}^*$  es un mínimo global de  $f$  en  $\mathcal{S}$ .

**Demostración.** Dado que  $\mathbf{x} - \mathbf{x}^*$  es una dirección factible en  $\mathbf{x}^*$ , la condición  $\nabla f(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) \geq 0$  es equivalente a una condición necesaria de primer orden para un mínimo. Por otro lado, la condición de primer orden para funciones convexas establece que

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) \geq f(\mathbf{x}^*)$$

lo cual concluye la demostración.  $\square$

La maximización de una función convexa en un conjunto convexo suele presentar numerosos máximos locales. Sin embargo, es posible demostrar un resultado importante.

**Teorema 15** Sea  $\mathcal{S} \neq \emptyset$  un conjunto compacto y convexo en  $\mathbb{R}^n$ , y sea  $f : \mathcal{S} \rightarrow \mathbb{R}$  una función convexa en  $\mathcal{S}$ . Luego, si  $f$  tiene un máximo en  $\mathcal{S}$ , éste ocurre en un punto extremo de  $\mathcal{S}$ .

**Demostración.** Ver Luenberger p 181, Teorema 3.  $\square$